

X-ray 검사장비 AI 데이터셋



| 스마트팩토리 동아리 C조 |

목차

1. 분석 배경
2. 분석 목표
3. 제조 데이터 소개
4. 분석 모델 소개
5. 결과 분석

1. 분석 배경

1.1 설비종류 : X-ray 검사기



- 엑스레이 투사를 통해 내부상태를 확인
- 금속 및 이물질 포함 여부 검출
- 포장 공정 마지막 단계에 주로 사용

1. 분석 배경

1.2 공정 상의 이슈

- 생산라인의 마지막 단계이므로 판정오류가 없는 것이 매우 중요
- 이중 삼중 검사를 하게 되면 미검, 과검의 문제 여전히 발생
- 생산흐름, 작업동선, 중복작업으로 인한 비용낭비 야기
- 장비의 기술적 한계 -> 모든 불량을 발견하지 못할 가능성 존재

2. 분석 목표

→ 검사장비를 교체하지 않으면서 기술적 한계를 보완 해야함

검사장비로 부터 X-ray 이미지 수집



이미지로 부터 결함종류 라벨링 작업



YOLO v3 모델을 통해 포장제품의 양품/불량품을 정확하게 판정

3. 제조 데이터 소개

3.1 데이터 수집 방법

- 제조 분야 : 분무건조공법을 이용한 분말유크림 제조
- 제조 공정명 :포장공정 비전검사 단계
- 수집장비 : X-RAY 이물검출기 SD Card
- 수집기간 : 2020년 6월 23일 ~ 2020년 9월 22일 (약 3개월)
- 수집 주기 : 불규칙(검사장비를 통과하는 제품이 불량일 경우에만 이미지를 저장한다)

3. 제조 데이터 소개

3.2 데이터 유형/구조


[1호기 폴더] - 1,031개 / 112MB

[2호기 폴더] - 920개 / 92.9MB


[3호기 폴더] - 858개 / 210MB

총 데이터 수 = 2,809개 / 415MB

➡ 본 분석에서는 15개의 이미지에 대해 결함 객체 탐지를 진행함.



[그림 2] 결함이 검출된 불량품의 X-RAY 사진 예시



[그림 1] X-RAY 이물검출기 이미지 데이터 스크린샷

3. 제조 데이터 소개

3.2 데이터 유형/구조

• 데이터 속성정의 표 :

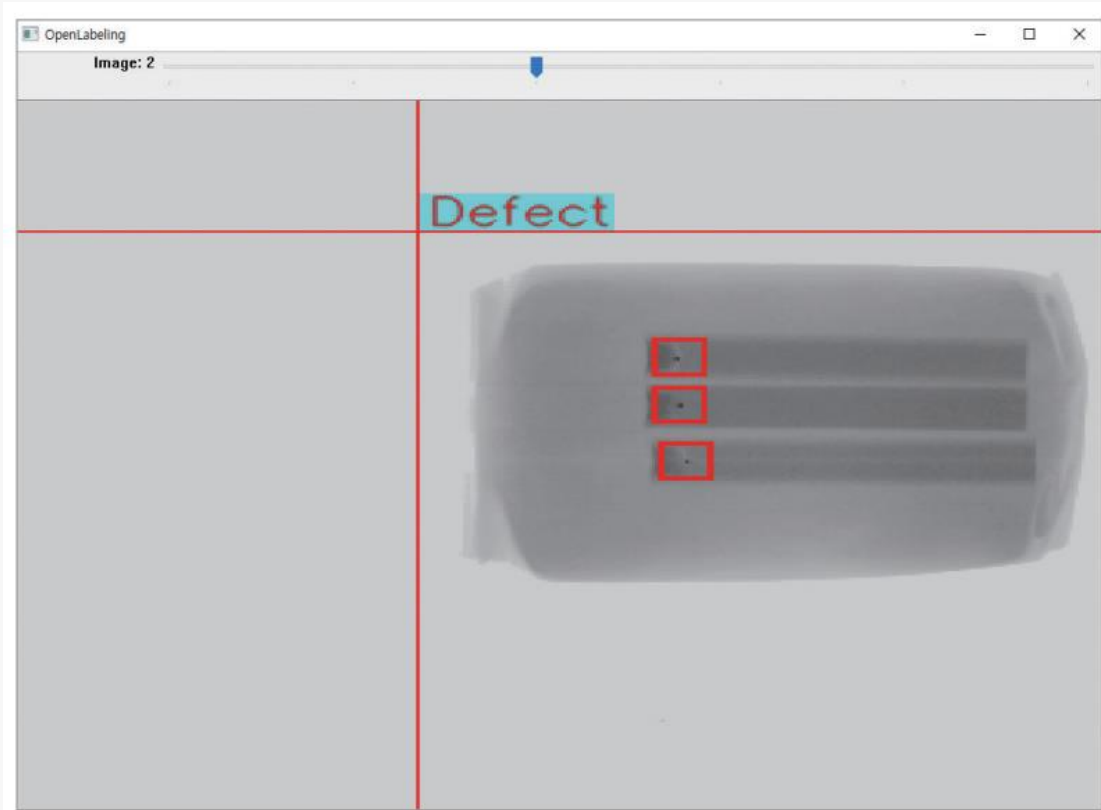
변수명	설 명	데이터 타입
SN_NglImage	X선이물검출기를 통해 수집된 X-RAY상 결함(defect)이 검출되어 표시된 이미지	BMP형식 이미지 파일 (.bmp)
SN_NglImage_Label	이미지의 결함 좌표(위치)를 나타내는 텍스트 파일	텍스트 파일 (.txt)

• 독립변수/종속변수 정의 :

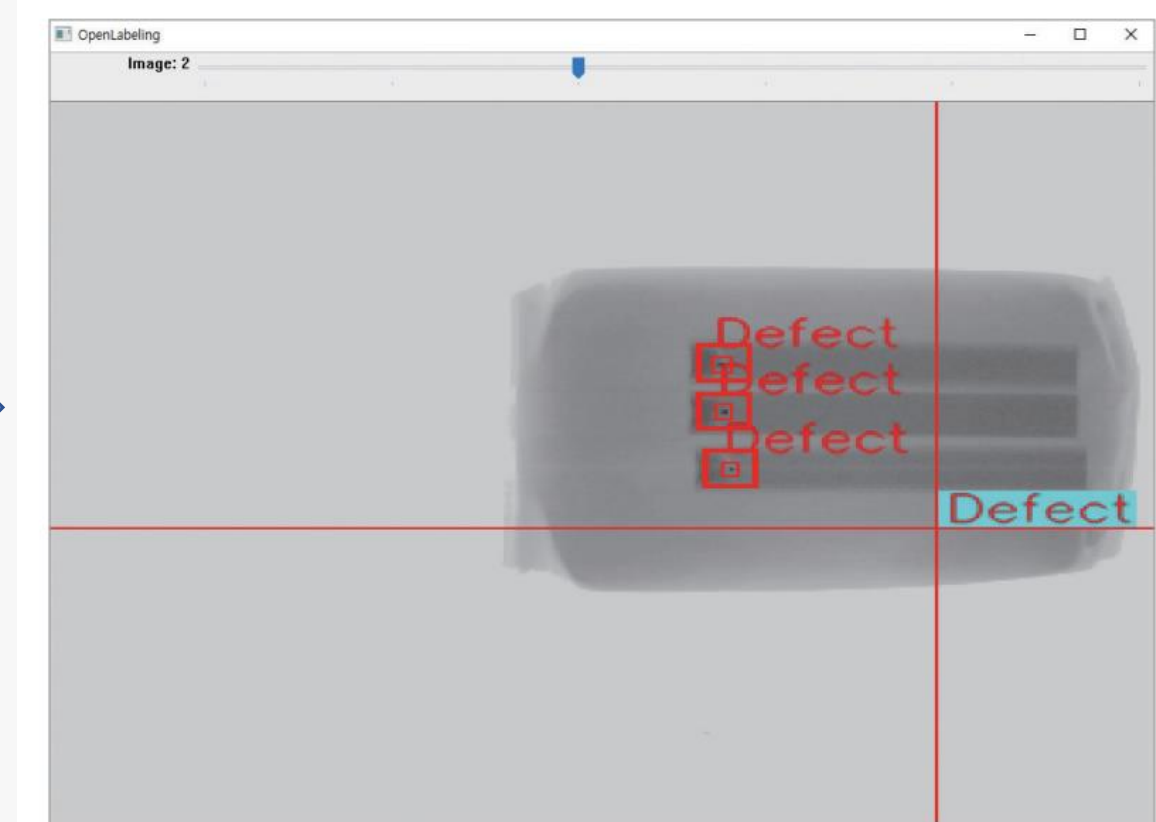
구 분	명 칭	
독립변수	X-RAY 이미지	결함이 포함된 이미지(BMP) 파일
	결함 좌표	이미지 파일의 결함(Defect)에 대해 좌표 정보가 담겨있는 TXT(텍스트) 파일
종속변수	객체탐지 이미지	객체탐지(Object Detection) 박스가 표시된 이미지(JPG) 파일

3. 제조 데이터 소개

- 데이터 Labeling



[그림 39] Labeling tool 프로그램 실행 화면

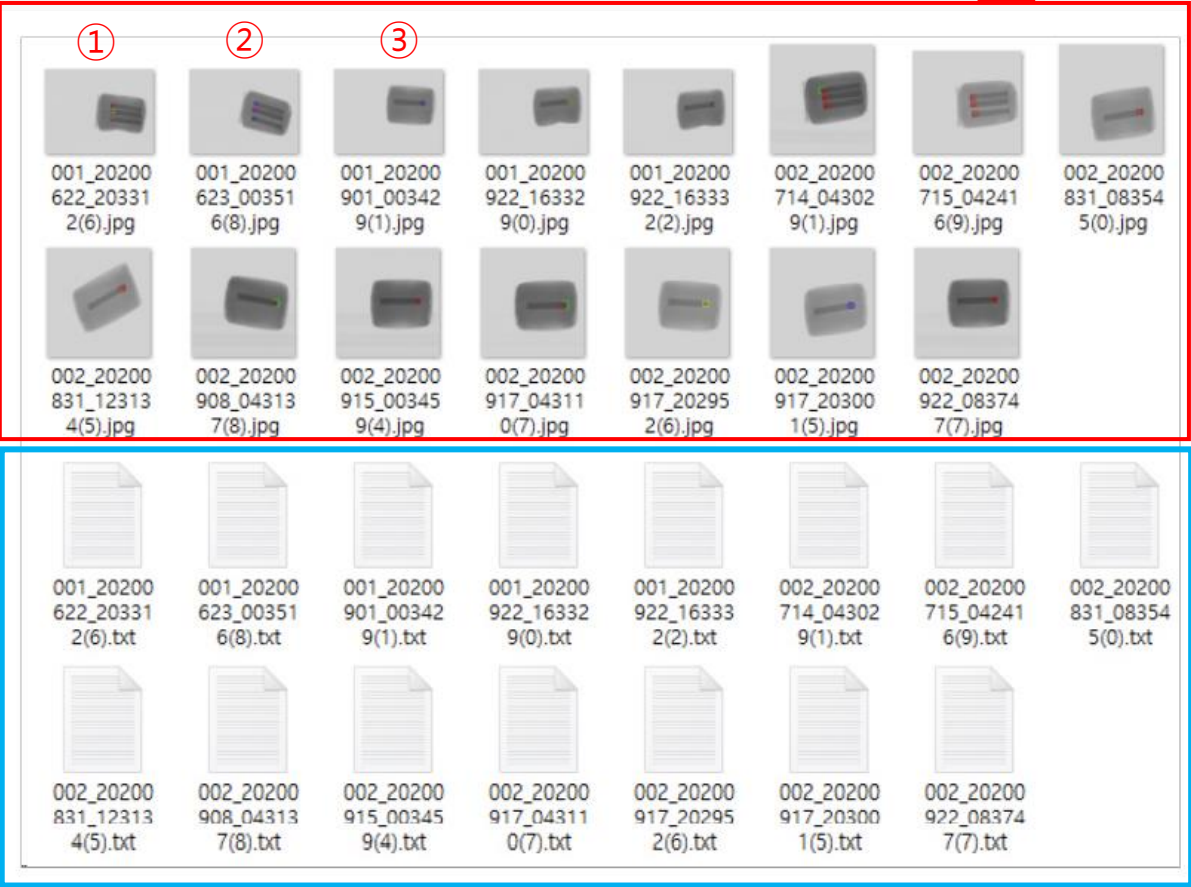


[그림 40] 이미지의 모든 결함(defect)에 라벨링을 수행한 결과

3. 제조 데이터 소개

- 독립변수

Labeling 해야 할 데이터



① 001_20200622_203312(6) - Windows 메모장

파일(F) 편집(E) 서식(O) 보기(V) 도움말(H)

```
0 0.6310763888888888 0.4346846846846847 0.008680555555555556 0.013513513513513514
0 0.6302083333333334 0.5056306306306306 0.013888888888888888 0.015765765765765764
0 0.6293402777777778 0.5900900900900901 0.012152777777777778 0.018018018018018018
```

② 001_20200623_003516(8) - Windows 메모장

파일(F) 편집(E) 서식(O) 보기(V) 도움말(H)

```
0 0.6119791666666666 0.4132882882882883 0.005208333333333333 0.015765765765765764
0 0.6076388888888888 0.4864864864864865 0.006944444444444444 0.013513513513513514
0 0.6015625 0.5900900900900901 0.008680555555555556 0.013513513513513514
```

③ 001_20200901_003429(1) - Windows 메모장

파일(F) 편집(E) 서식(O) 보기(V) 도움말(H)

```
0 0.8203125 0.40765765765765766 0.012152777777777778 0.013513513513513514
```

↓ Class ↓ X축좌표 ↓ Y축좌표 ↓ width ↓ height

[그림 42] 라벨링 작업 수행 후의 원본 이미지와 라벨링 좌표가 포함된 텍스트 파일

Labeling 좌표

3. 제조 데이터 소개

Test : train = 2 : 8

test - Windows 메모장

파일(F) 편집(E) 서식(O) 보기(V) 도움말(H)

images/001_20200622_203312(6).jpg
images/001_20200623_003516(8).jpg
images/002_20200915_003459(4).jpg

train - Windows 메모장

파일(F) 편집(E) 서식(O) 보기(V) 도움말(H)

images/001_20200901_003429(1).jpg
images/001_20200922_163329(0).jpg
images/001_20200922_163332(2).jpg
images/002_20200714_043029(1).jpg
images/002_20200715_042416(9).jpg
images/002_20200831_083545(0).jpg
images/002_20200831_123134(5).jpg
images/002_20200908_043137(8).jpg
images/002_20200917_043110(7).jpg
images/002_20200917_202952(6).jpg
images/002_20200917_203001(5).jpg
images/002_20200922_083747(7).jpg

```
Anaconda Prompt

(base) C:\wtest1\yolov3>cd C:\wtest1\yolov3

(base) C:\wtest1\yolov3>python detect.py --weights weights/last.pt --source images
--cfg yolov3-spp.cfg --names classes.names --output result
Namespace(agnostic_nms=False, augment=False, cfg='yolov3-spp.cfg', classes=None,
conf_thres=0.3, device='', fourcc='mp4v', half=False, img_size=512, iou_thres=0.6,
names='classes.names', output='result', save_txt=False, source='images', view_i
mg=False, weights='weights/last.pt')
Using CUDA device0 _CudaDeviceProperties(name='GeForce RTX 2060', total_memory=61
44MB)




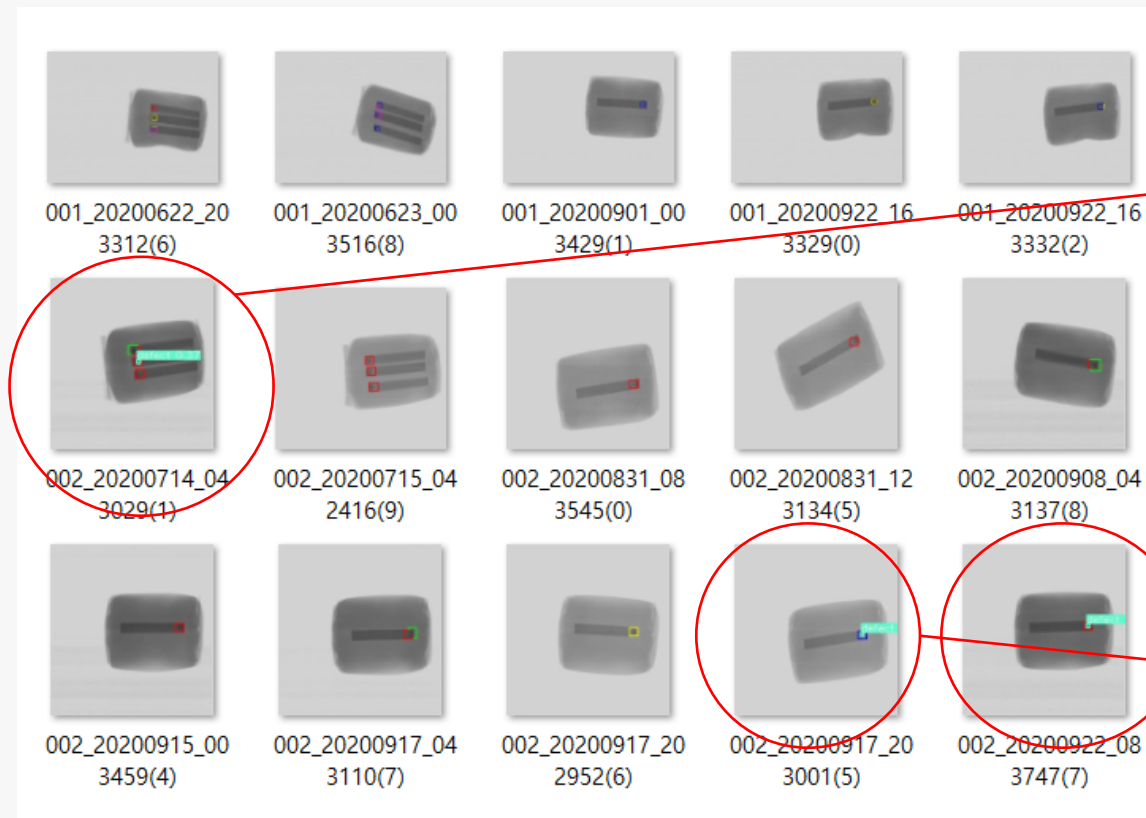
Model Summary: 225 layers, 6.25733e+07 parameters, 6.25733e+07 gradients
image 1/15 images\001_20200622_203312(6).jpg: 416x512 Done. (0.026s)
image 2/15 images\001_20200623_003516(8).jpg: 416x512 Done. (0.026s)
image 3/15 images\001_20200901_003429(1).jpg: 416x512 Done. (0.027s)
image 4/15 images\001_20200922_163329(0).jpg: 416x512 Done. (0.026s)
image 5/15 images\001_20200922_163332(2).jpg: 416x512 Done. (0.026s)
image 6/15 images\002_20200714_043029(1).jpg: 512x512 1 defects, Done. (0.030s)
image 7/15 images\002_20200715_042416(9).jpg: 512x512 Done. (0.030s)
image 8/15 images\002_20200831_083545(0).jpg: 512x512 Done. (0.024s)
image 9/15 images\002_20200831_123134(5).jpg: 512x512 Done. (0.025s)
image 10/15 images\002_20200908_043137(8).jpg: 512x512 Done. (0.024s)
image 11/15 images\002_20200915_003459(4).jpg: 512x512 Done. (0.024s)
image 12/15 images\002_20200917_043110(7).jpg: 512x512 Done. (0.024s)
image 13/15 images\002_20200917_202952(6).jpg: 512x512 Done. (0.025s)
image 14/15 images\002_20200917_203001(5).jpg: 512x512 1 defects, Done. (0.024s)
image 15/15 images\002_20200922_083747(7).jpg: 512x512 1 defects, Done. (0.023s)
Results saved to C:\wtest1\yolov3\result
Done. (1.456s)

(base) C:\wtest1\yolov3>
```

[그림 78] 객체 탐지 수행 과정 중 출력되는 내용

3. 제조 데이터 소개

- 종속변수



4. 분석 모델 소개


객체탐지(Object Detection) 모델 : YOLOv3

- 객체탐지란 ?



Object Classification is the task of identifying that picture is a dog

분류

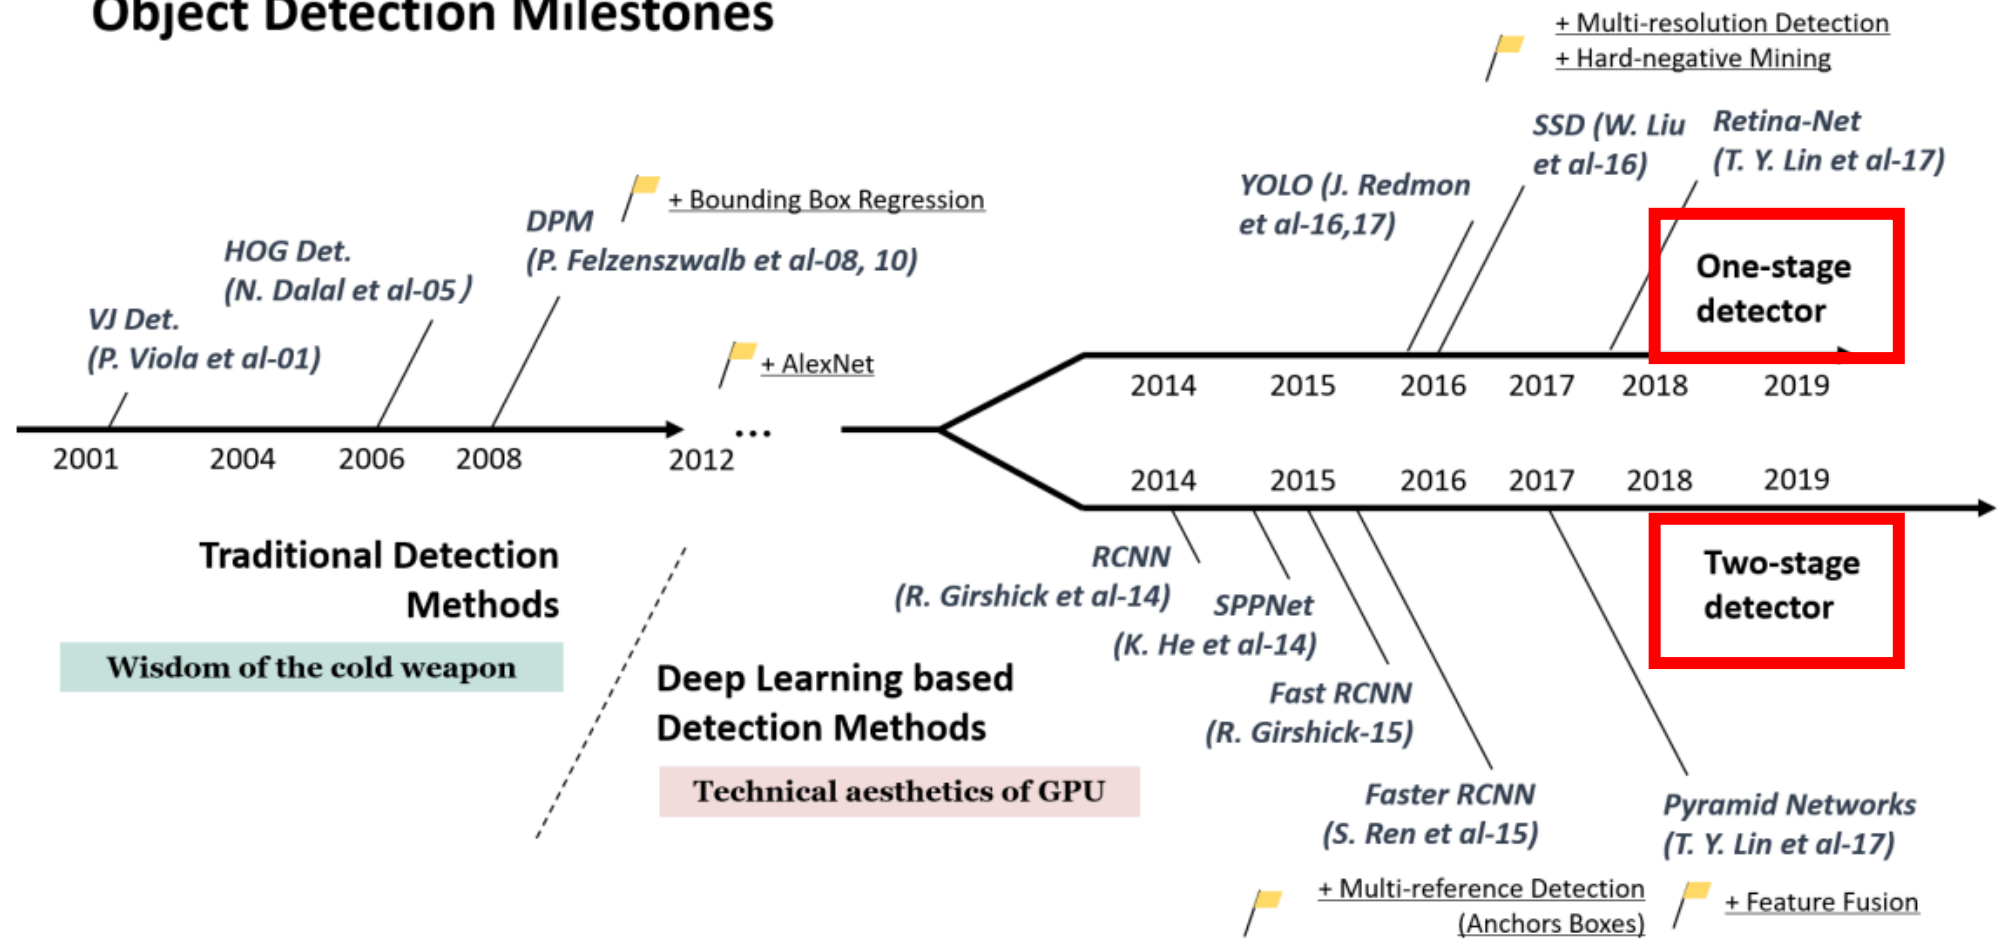


Object Localization involves the class label as well as a bounding box to show where the object is located.

객체탐지

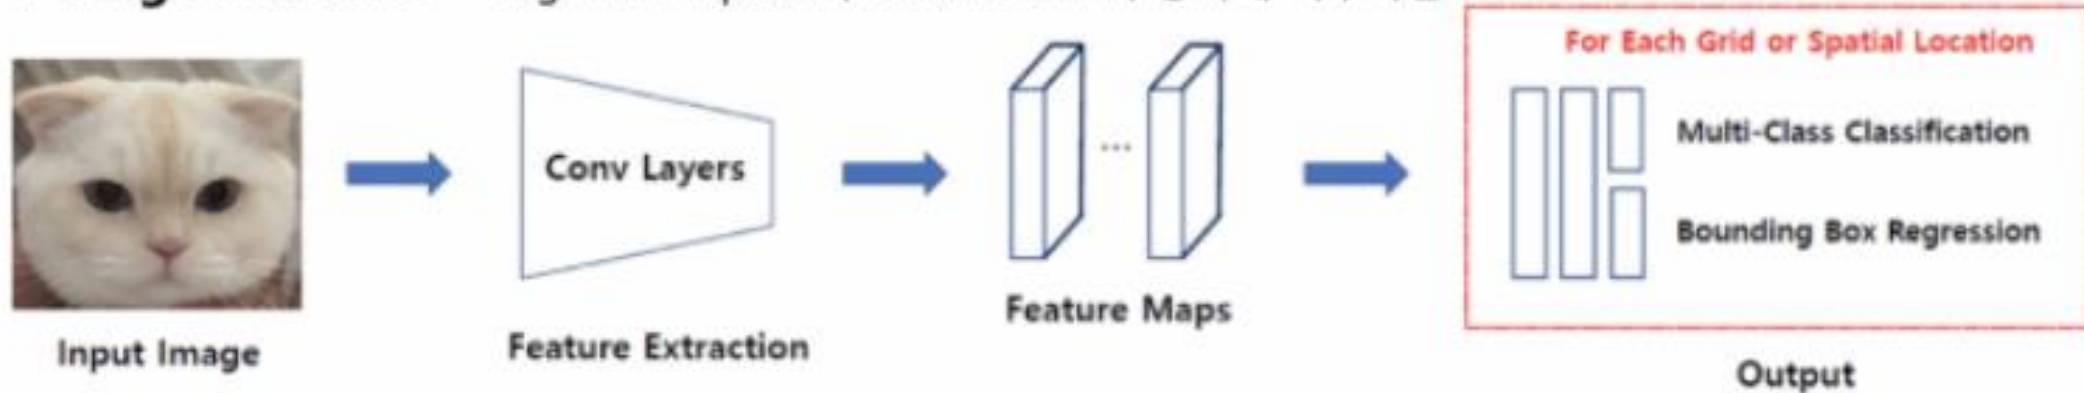
4. 분석 모델 소개

Object Detection Milestones

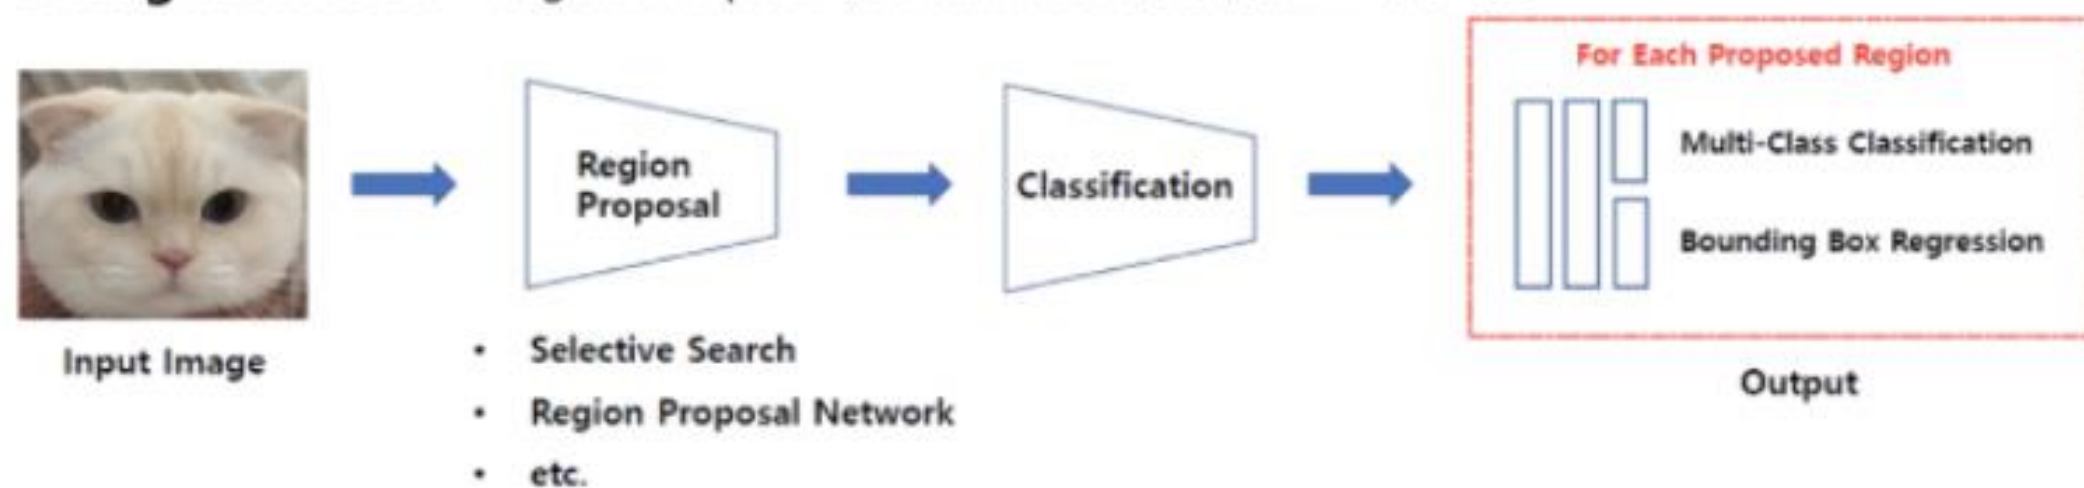


4. 분석 모델 소개

1-Stage Detector - Regional Proposal와 Classification이 동시에 이루어짐.




2-Stage Detector - Regional Proposal와 Classification이 순차적으로 이루어짐.



4. 분석 모델 소개

Year	Object Detection Model	COCO Dataset (mAP@IoU=0.5:0.95)	Conference
2014	R-CNN	-	CVPR
2015	Fast R-CNN	19.7	ICCV
2015	Faster R-CNN	21.9	NIPS
2016	YOLO v1	-	CVPR
2016	SSD	31.2	ECCV
2017	DSSD	33.2	arXiv
2017	TDM	37.3	CVPR
2017	FPN	36.2	CVPR
2017	YOLO v2	-	CVPR
2017	DeNet	33.8	ICCV
2017	CoupleNet	34.4	ICCV
2017	RetinaNet	39.1	ICCV
2017	DSOD	-	ICCV
2017	SMN	-	ICCV
2018	YOLO v3	33	arXiv

[그림 4] : 여러 학회에서 제시된 객체 탐지 모델의 종류와 COCO 데이터셋에 대한 성능



[그림 3] 정확도와 속도에 관하여 논문에서 주장하는 YOLOv3의 성능

* Redmon, Joseph, and Ali Farhadi. "Yolov3: An incremental improvement." arXiv preprint arXiv:1804.02767 (2018).

4. 분석 모델 소개

객체탐지(Object Detection) 모델 : YOLOv3

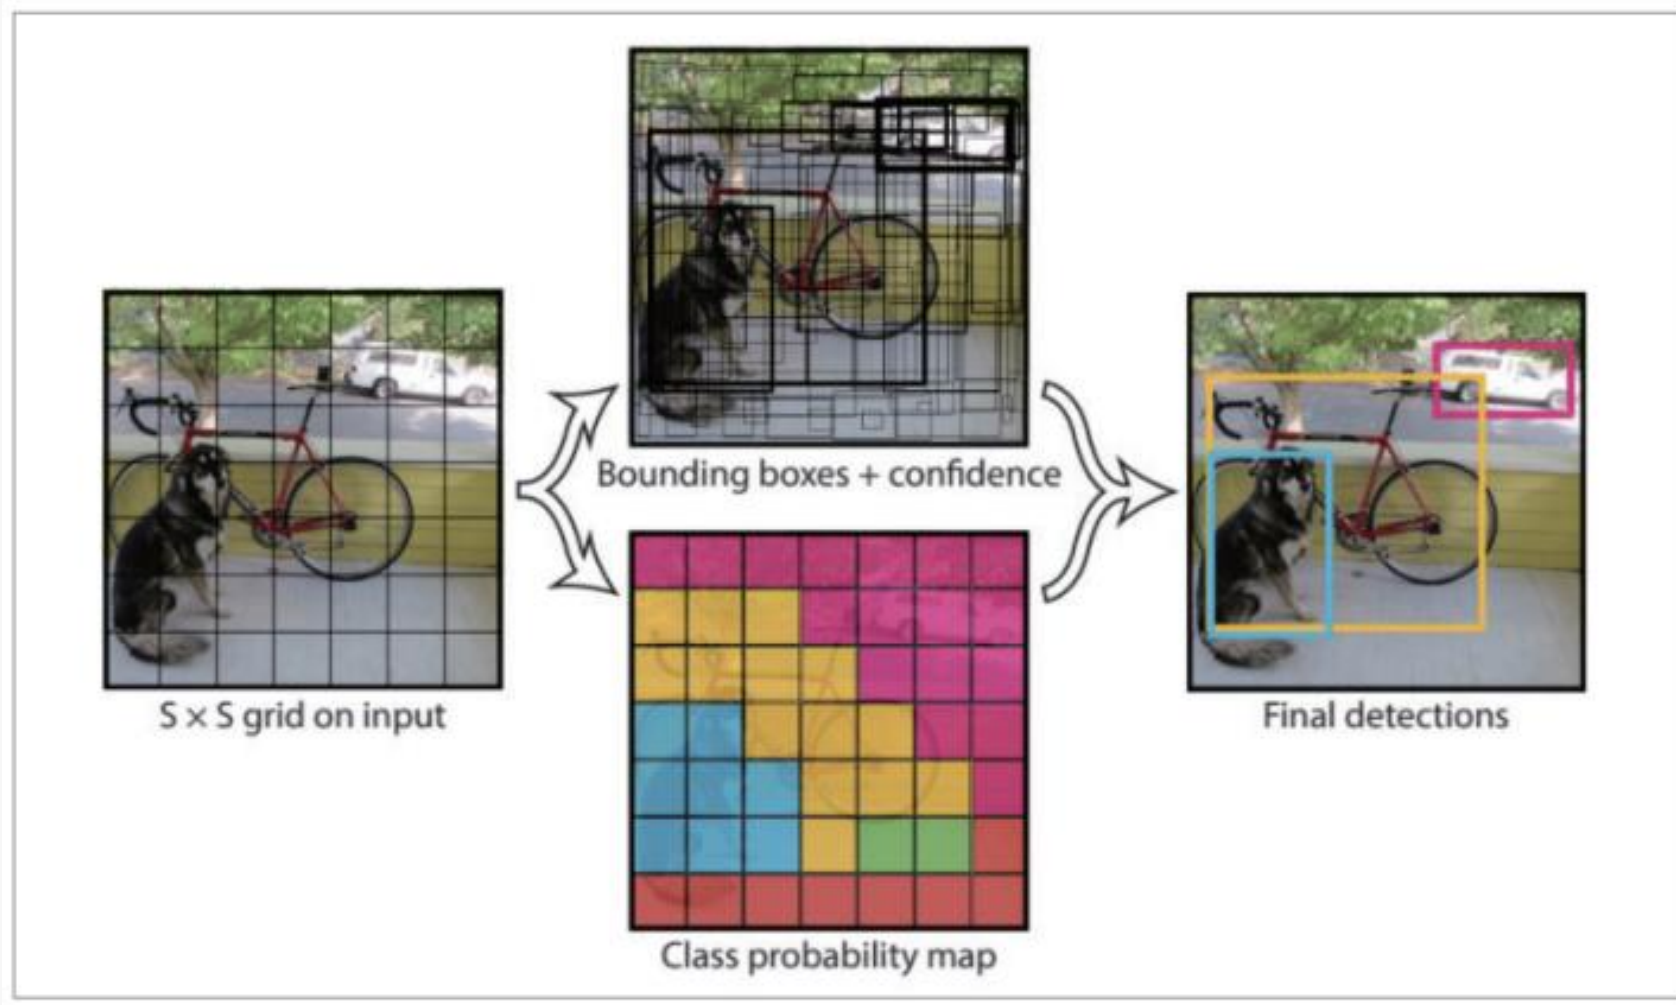
- You Only Look Once: Unified, real-time object detection(2015)
- YOLO9000: Better, Faster, Stronger(2016)
- YOLOv3: An Incremental Improvement(2018)

Abstract

*We present YOLO, a new approach to object detection. Prior work on object detection repurposes classifiers to perform detection. Instead, we frame **object detection** as a **regression problem** to spatially separated bounding boxes and associated class probabilities. A **single neural network** predicts bounding boxes and class probabilities directly from full images in one evaluation. Since the whole detection pipeline is a single network, it can be optimized end-to-end directly on detection performance.*


4. 분석 모델 소개

객체탐지(Object Detection) 모델 : YOLOv3



4. 분석 모델 소개

객체탐지(Object Detection) 모델 : YOLOv3



[그림 8] 그리드별 예측 정보로 경계상자를 조정하여 분류 수행

4. 분석 모델 소개

객체탐지(Object Detection) 모델 : YOLOv3

$$w \times h \times (\text{각각의 그리드에서 갖는 Bounding box의 후보 갯수}) \times 5 + (\text{Class의 갯수})$$

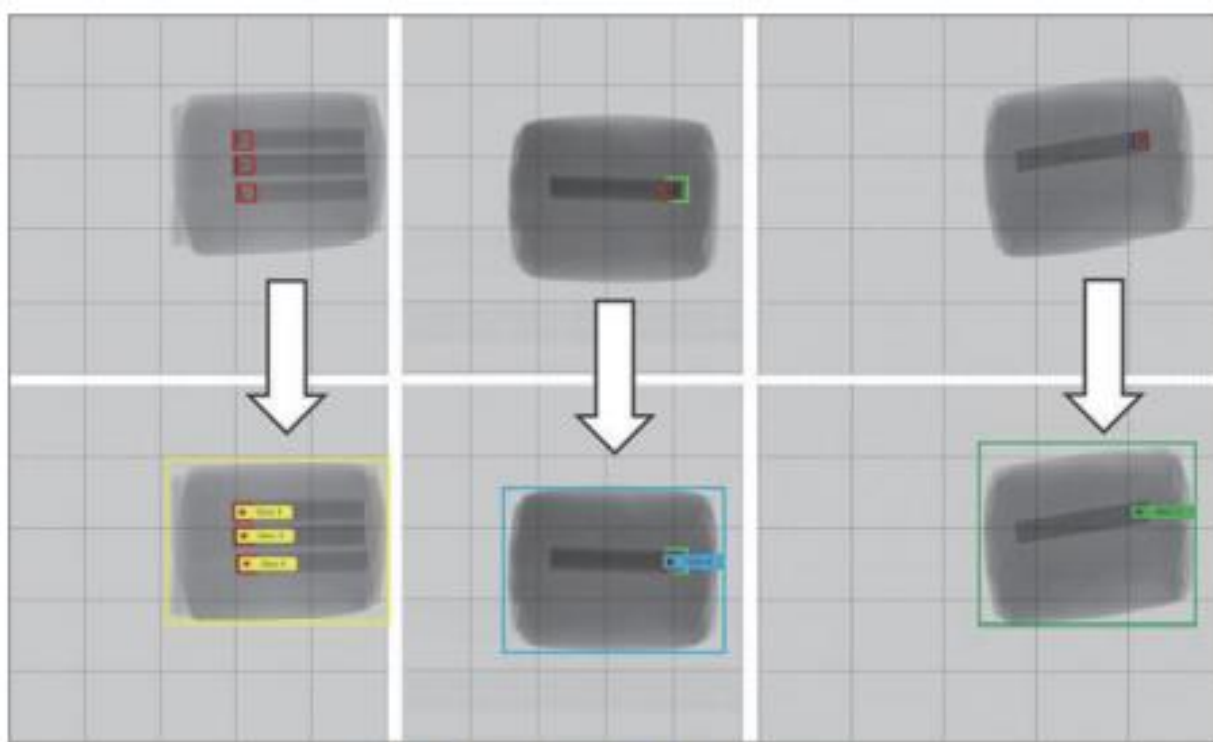
<p>loss function:</p> $\lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{obj} [(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2]$ $+ \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{obj} [(\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2]$ <p>(Size & Location of Bounding box) (Sum squared error for optimize)</p> $+ \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{obj} (C_i - \hat{C}_i)^2$ $+ \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{noobj} (C_i - \hat{C}_i)^2$ <p>(Object detection)</p> $+ \sum_{i=0}^{S^2} \mathbb{I}_i^{cls} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2$ <p>(Class)</p>	<p>Key Parameter:</p> <p>Coordinate Loss + Confidence-Score Loss + No-Object Penalties + Classification Loss</p> <p>w, h: 그리드 가로 세로 S: Number of grid C: Confidence score B: 그리드 내 box 수 x, y: Bounding box 중심좌표 {p(c)}: i cell의 object가 해당 Class에 속할 확률 $\lambda_{coord}, \lambda_{noobj}$: Bounding box에 대한 값 조정 $\mathbb{I}_i^{obj}, \mathbb{I}_i^{noobj}$: 1 or 0 object 여부 확인</p>
--	---

[그림 9] YOLO 기본 학습 과정 수식

4. 분석 모델 소개

객체탐지(Object Detection) 모델 : YOLOv3

- 경계 상자(Bounding Box)의 중심과 너비와 높이
- 경계 상자(Bounding Box)가 객체(Object)를 포함하고 있을 확률
- 객체(Object)가 속한 클래스



[그림 11] YOLO 내부 프로세스에 따른 기대결과 출력 샘플

4. 분석 모델 소개

객체탐지(Object Detection) 모델 : YOLOv3

		객체 탐지 결과	
		양품	불량
실제	양품	양품정탐(TP)	양품과검(FN) 잘못 검출된 것
	불량	불량미검(FP) 옳은 검출	불량정탐(TN)

검출되어야 할 것이
검출되지 않은 것

$$\text{정밀도(Precision)} = \frac{TP}{TP+FP} = \frac{TP}{\text{모든 검출}}$$

$$\text{재현율(Recall)} = \frac{TP}{TP+FN} = \frac{TP}{\text{실제 모든 양품}}$$

4. 분석 모델 소개

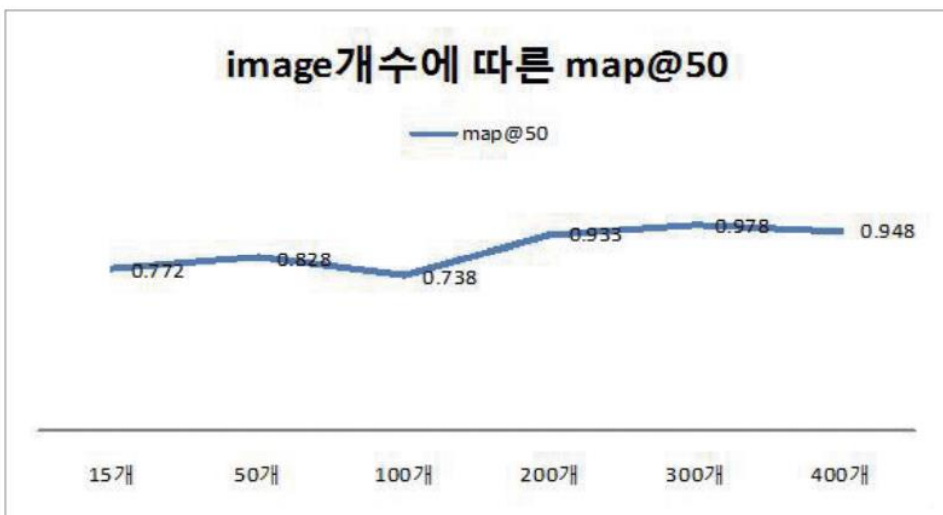
객체탐지(Object Detection) 모델 : YOLOv3

$$F1Score = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}}$$

- mAP(mean Average Precision) : 재현율 값들에 대응하는 정밀도 값들의 평균인 AP(Average Precision)를 객체(object)별로 구하고, 여러 객체 탐색된 결과에 대하여 평균(mean)값을 구한 것이 mAP이다.


5. 결과 분석

image개수에 따른 map@50




[그림 87] 이미지 개수에 따른 map@50 변화 추이

image 개수에 따른 precision




[그림 88] 이미지 개수에 따른 정밀도 변화 추이

image 개수에 따른 recall



[그림 89] 이미지 개수에 따른 재현율 변화 추이

image개수에 따른 f1score



[그림 90] 이미지 개수에 따른 조화평균 변화 추이

➡ 최적 이미지 수
200개